






TURMA DO CLASSROOM



# Péricles Leite

CIÊNCIA DA COMPUTAÇÃO



- Estudante de CC (4ºP)
- Membro do Colegiado de CC
- Diretor de CC (Calicomp)
- Vice Presidente (LaIA)
- Pesquisador - Análise de Dados Econômicos (DEE)

TURING






# CONCETTOS


REDES DE CAMADAS  
TOTALMENTE CONECTADAS





NEURÔNIO HUMANO


# Perceptron



PERCEPTRON




- **Input:** dado de entrada
- **Peso:** significância do sinal
- **Bias:** constante de aumento ou diminuição do valor líquido obtido por  $xw$
- **Output:** sinal de saída



$$y = xw + b$$

# equação de reta

$$y = xw + b$$





LINEARIDADE





- Essas operações são lineares, de forma que, por mais complexa que seja a rede neural, ela só pode captar relações lineares entre as variáveis de entrada e a variável de saída.
- Para torná-las capazes de modelar também relações não-lineares, os resultados de saída de cada camada passaram a ser processados pelas chamadas funções de ativação

sigmoid





reLU



FUNÇÃO DE ATIVAÇÃO

## Como o peso e o bias altera a saída

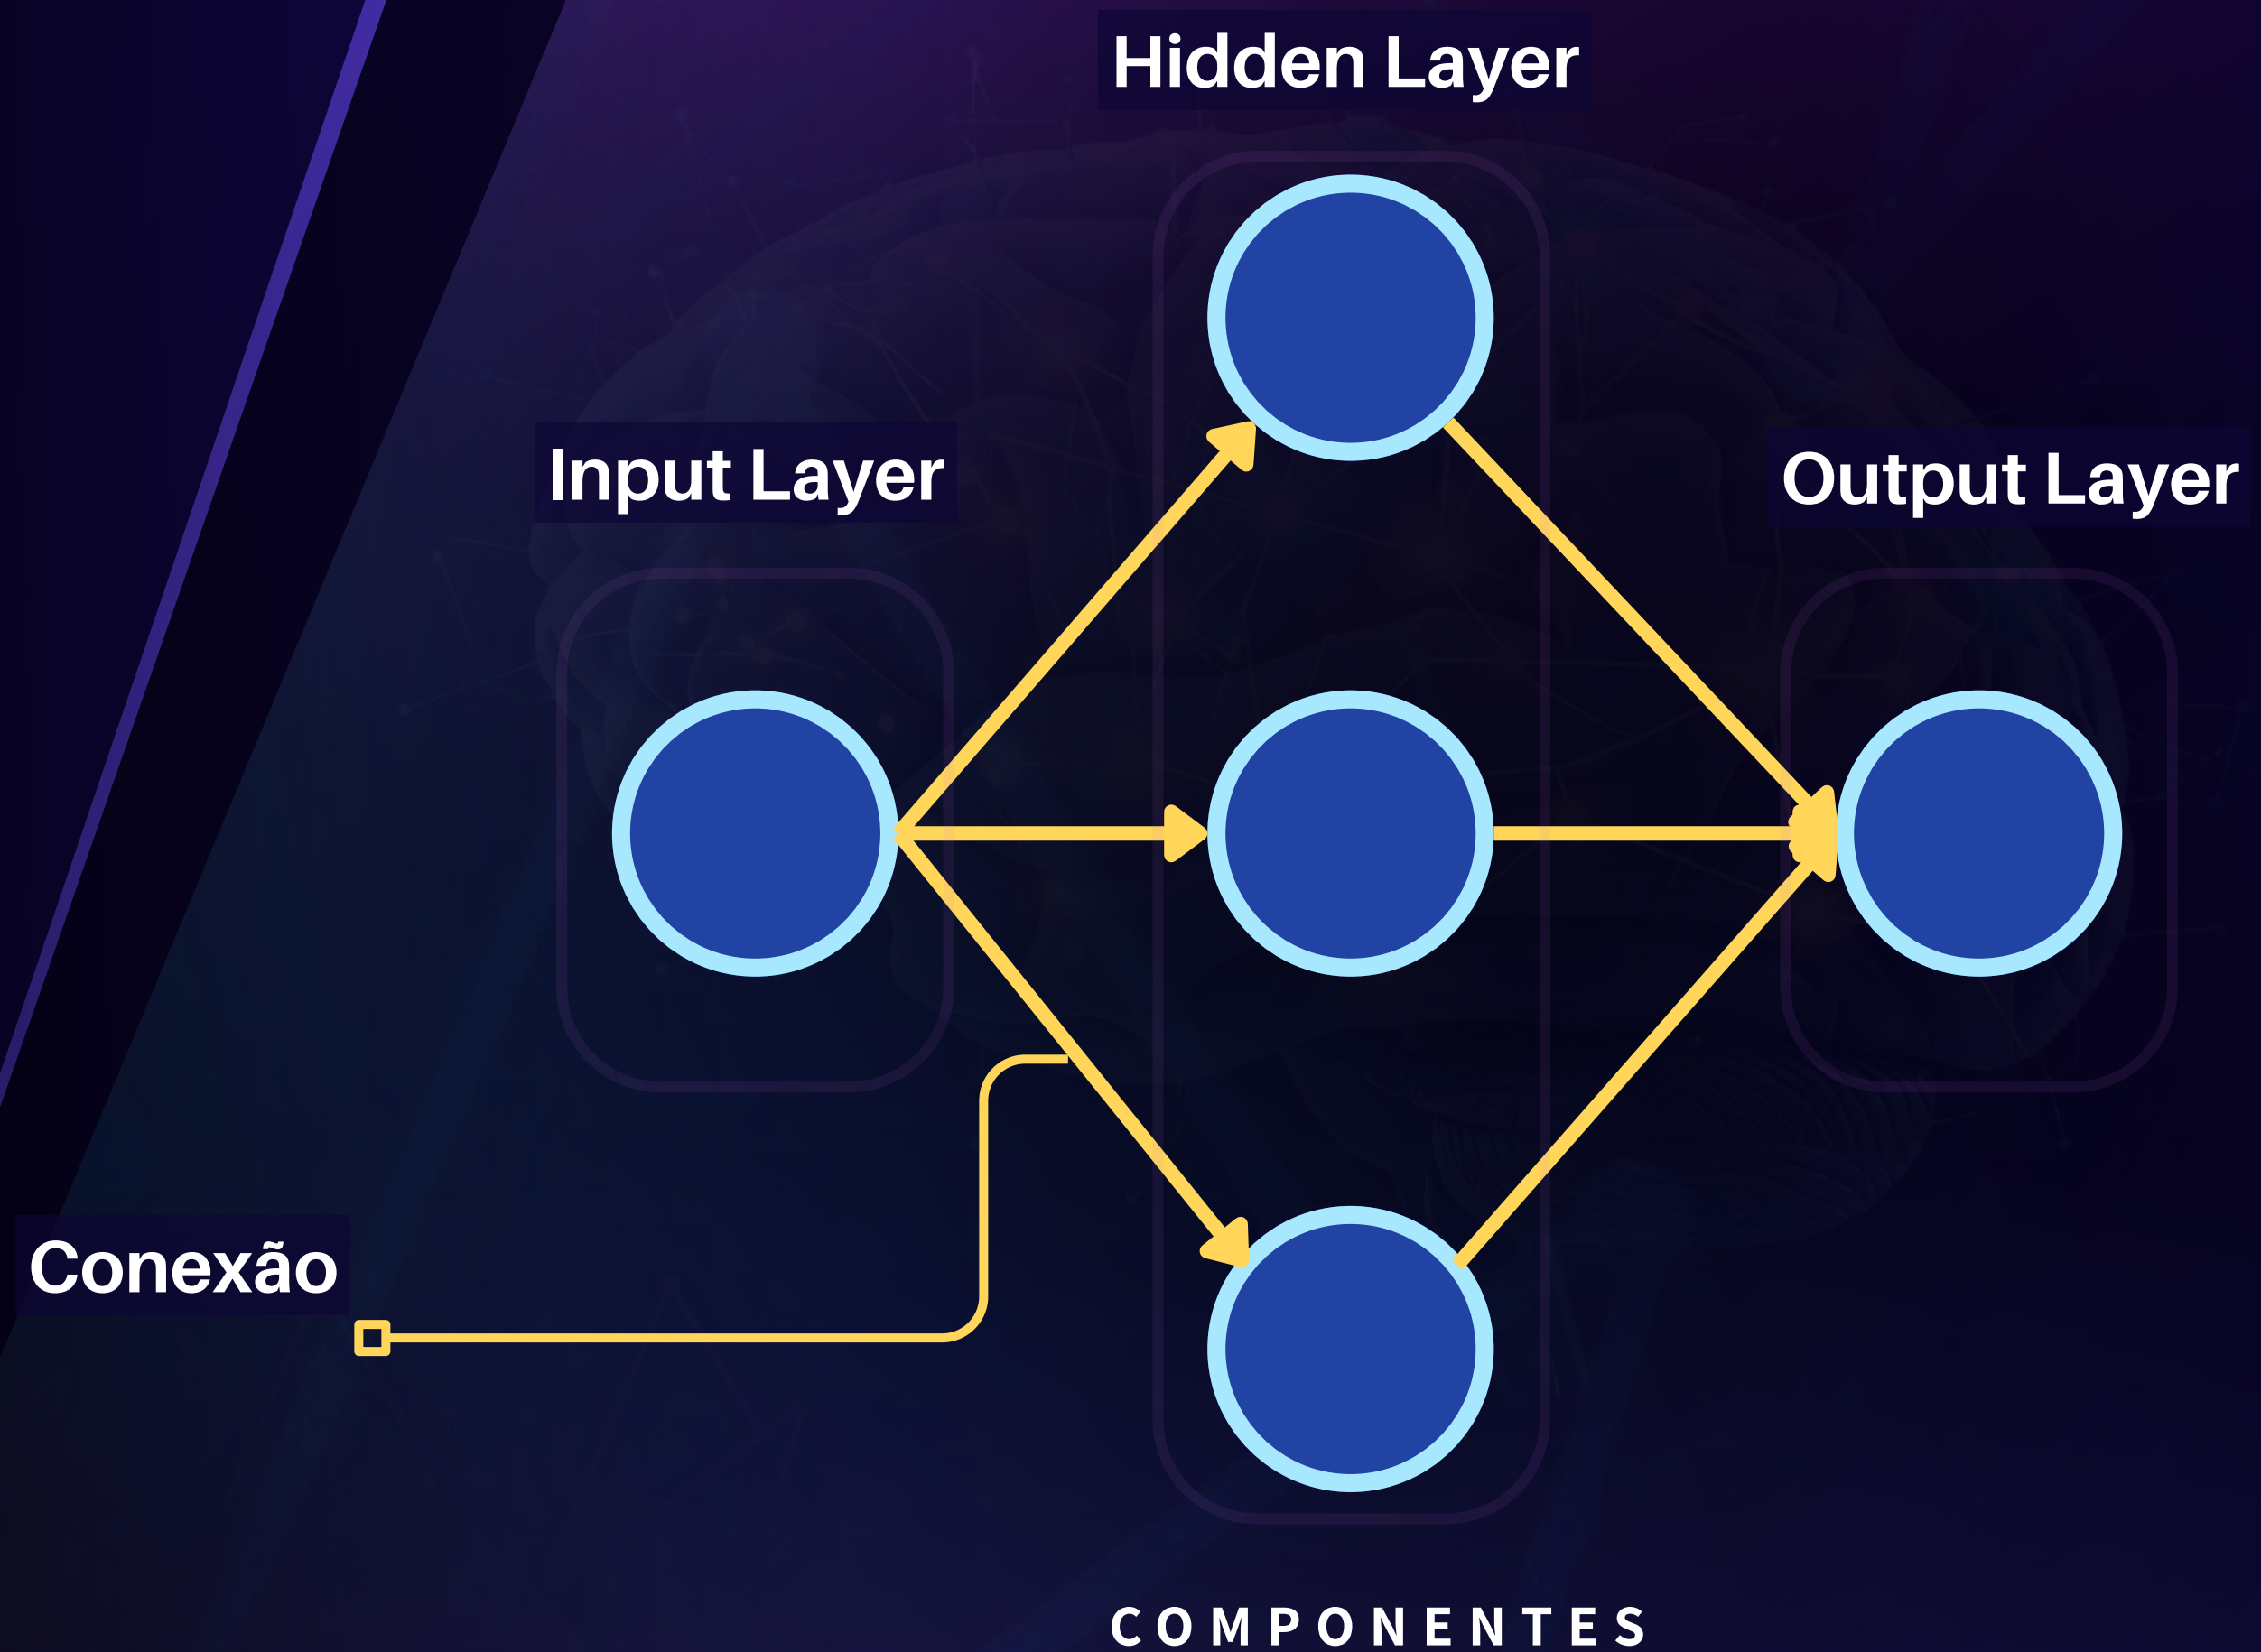
$$w_1 = 3.4, b_1 = 0$$



créditos: Machine  
Learning para humanos


P E S O E B I A S





## feedforward

- Em uma rede feedforward, cada camada se conecta à próxima camada, porém não há caminho de volta.
- Todas as conexões portanto, têm a mesma direção, partindo da camada de entrada rumo a camada de saída.



FEEDFORWARD

# Medidas de desempenho

- **classe positiva**

Representa o resultado de interesse, e responde a pergunta: Esse é o resultado que eu procurava?

- **classe negativa**

É a ausência da classe negativa (ex: o paciente não está doente)

- **legenda**

- VP (Verdadeiro Positivo): Acertos corretos da classe positiva.
- VN (Verdadeiro Negativo): Acertos corretos da classe negativa.
- FP (Falso Positivo): Erros onde o modelo previu positivo, mas era negativo.
- FN (Falso Negativo): Erros onde o modelo previu negativo, mas era positivo.



# Medidas de desempenho

- **acurácia**

proporção total de predições corretas (acertos gerais) sobre o número total de observações.

$$Acurácia = \frac{VP + VN}{VP + VN + FP + FN}$$

- **precisão**

Responde à pergunta: "Das vezes que o modelo previu positivo, quantas vezes ele acertou?"

$$Precisão = \frac{VP}{VP + FP}$$

- **recall**

Responde à pergunta: "De todos os casos positivos reais, quantos o modelo conseguiu encontrar?"

$$Recall = \frac{VP}{VP + FN}$$

- **f1 score**

É a média harmônica da Precisão e do Recall. Oferece um equilíbrio entre essas duas métricas em um único valor.

$$F1-Score = 2 \cdot \frac{Precisão \cdot Recall}{Precisão + Recall}$$



# DA ARQUITETURA

REDES DE CAMADAS  
TOTALMENTE CONECTADAS



## Por que classificar Imagens?

**Diagnóstico Médico**

**Controle de qualidade Industrial**

**Reconhecimento de objetos**


**Sistemas de Segurança**

**Mídia Social e Marketing**

REDES DE CAMADAS  
TOTALMENTE CONECTADAS



# Representação de imagens no computador



IMAGENS

# Definição

		224	222	226	234	221
	341	321	317	345	367	
154	156	158	160	163	317	224
156	158	163	216	224	321	234
154	156	158	160	163	321	226
158	168	116	224	234	341	234
160	163	173	186	221		

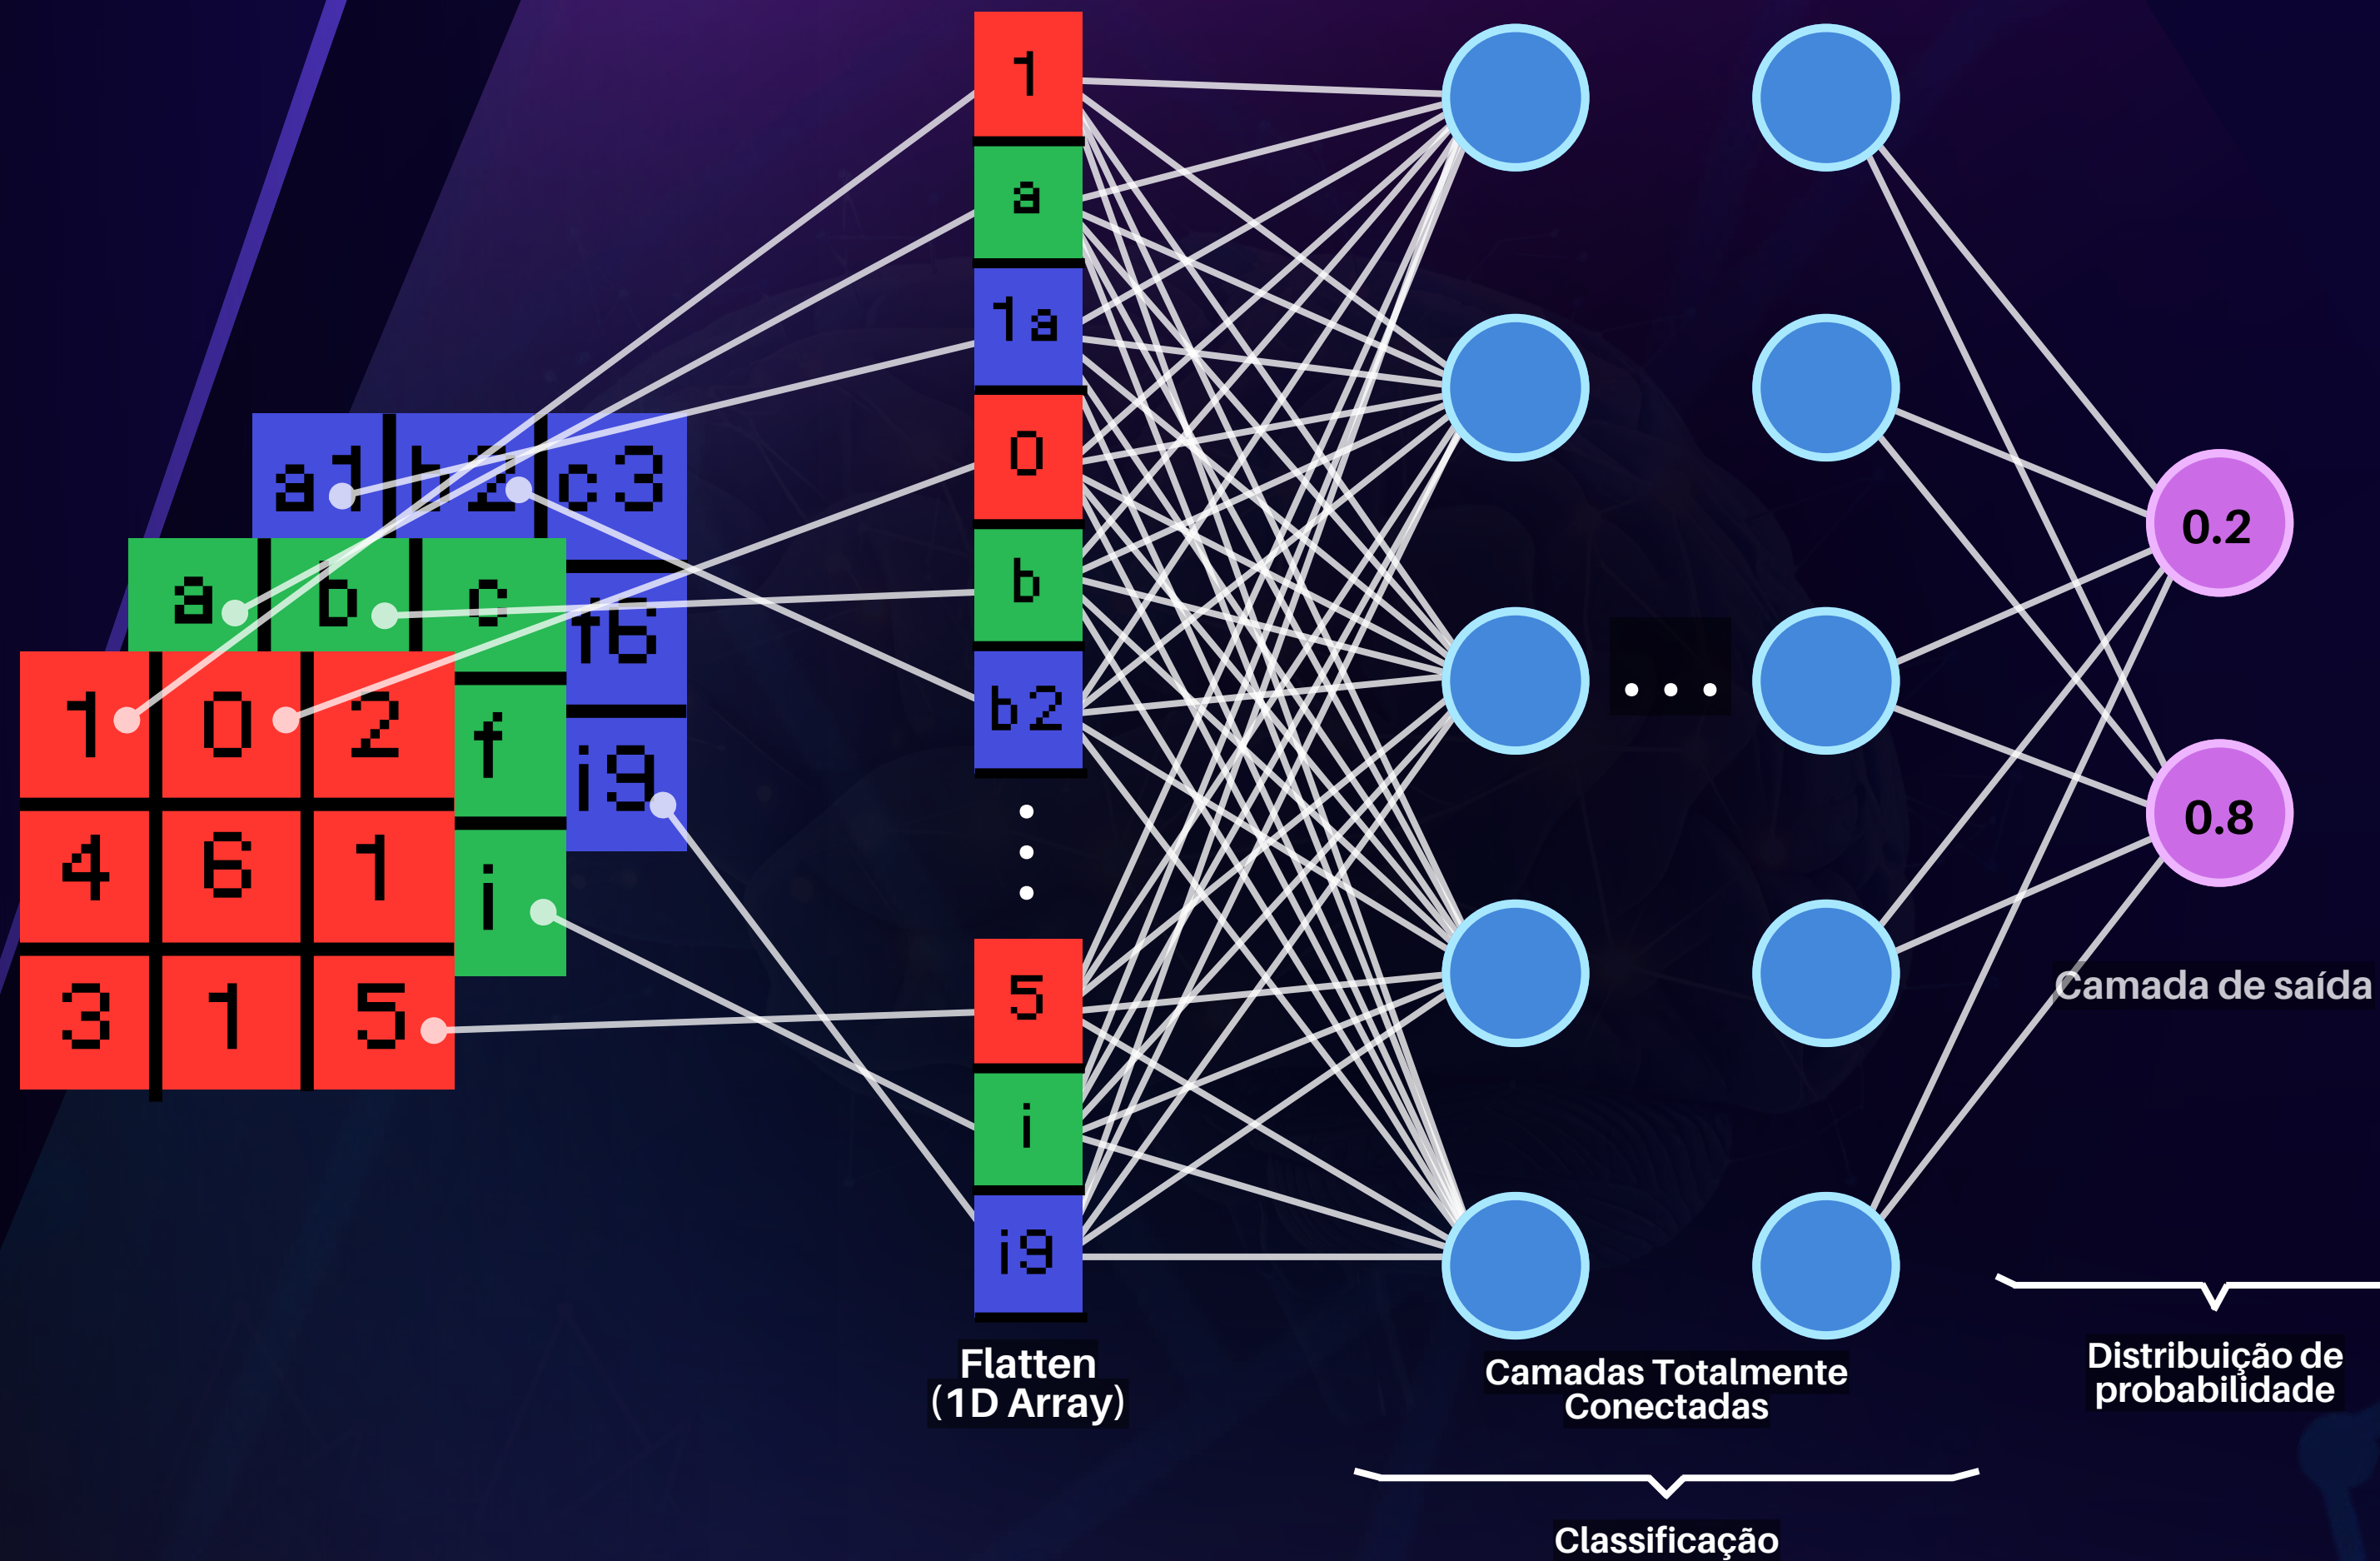
**(5x5)x3**

## IMAGENS

**Também chamada de Rede Neural Densa, As redes neurais de camadas totalmente conectadas são Redes de Perceptrons multicamadas.**

Ou seja, cada neurônio de uma camada conecta-se a todos os outros neurônios da camada seguinte.





TOTALMENTE CONECTADA

## **Classes dizem respeito aos rótulos usados para classificar algo**

Em modelos multi-classes, o número de neurônios da camada de saída é igual ao número de classes que o modelo pode prever. Saídas com 1 único neurônio são chamadas geralmente de classificação binária.

Modelos multirrótulo possuem múltiplas saídas independentes, onde cada saída indica a presença ou ausência de um rótulo específico, permitindo que uma mesma imagem pertença a várias classes.



**dataset original**

**seleção aleatória  
de dados**


normalização  
(Scaling)

**teste**

**validação**

**treino**

**DIVISÃO TREINO-TESTE-  
VALIDAÇÃO**







UNDERFIT E OVERFIT

**Underfitting é um problema que ocorre quando o modelo não consegue aprender padrões suficientes dos dados de treino, apresentando métricas ruins já no treinamento e, consequentemente, também baixo desempenho em validação e teste.**

Overfitting é um problema que aparece quando o modelo aprende tão bem com os dados de treino, incluindo ruídos e detalhes irrelevantes, que perde sua capacidade de generalização.



# MATEMÁTICA


REDES DE CAMADAS  
TOTALMENTE CONECTADAS





ERRO

muito errado



ótimo



ERRO

# funções de erro

mede o quão ruim está a parada

- previsão de valores contínuos

função de erro

- previsão de classes discretas

Regressão

Erro Médio Absoluto

Raiz do Erro Médio Absoluto

Raiz do Erro Médio Absoluto

Log cosh loss

Poisson

Classificação

Entropia Cruzada

Hinge Loss

Entropia Categórica Cruzada

LOSS FUNCTIONS

# funções de erro

## Entropia Cruzada

- padrão para tarefas de Classificação

$$\mathcal{H}(x, y) = -\sum_i p(x) \log_q(x)$$

- A superfície de perda possui o formato de uma curva de decaimento logarítmico

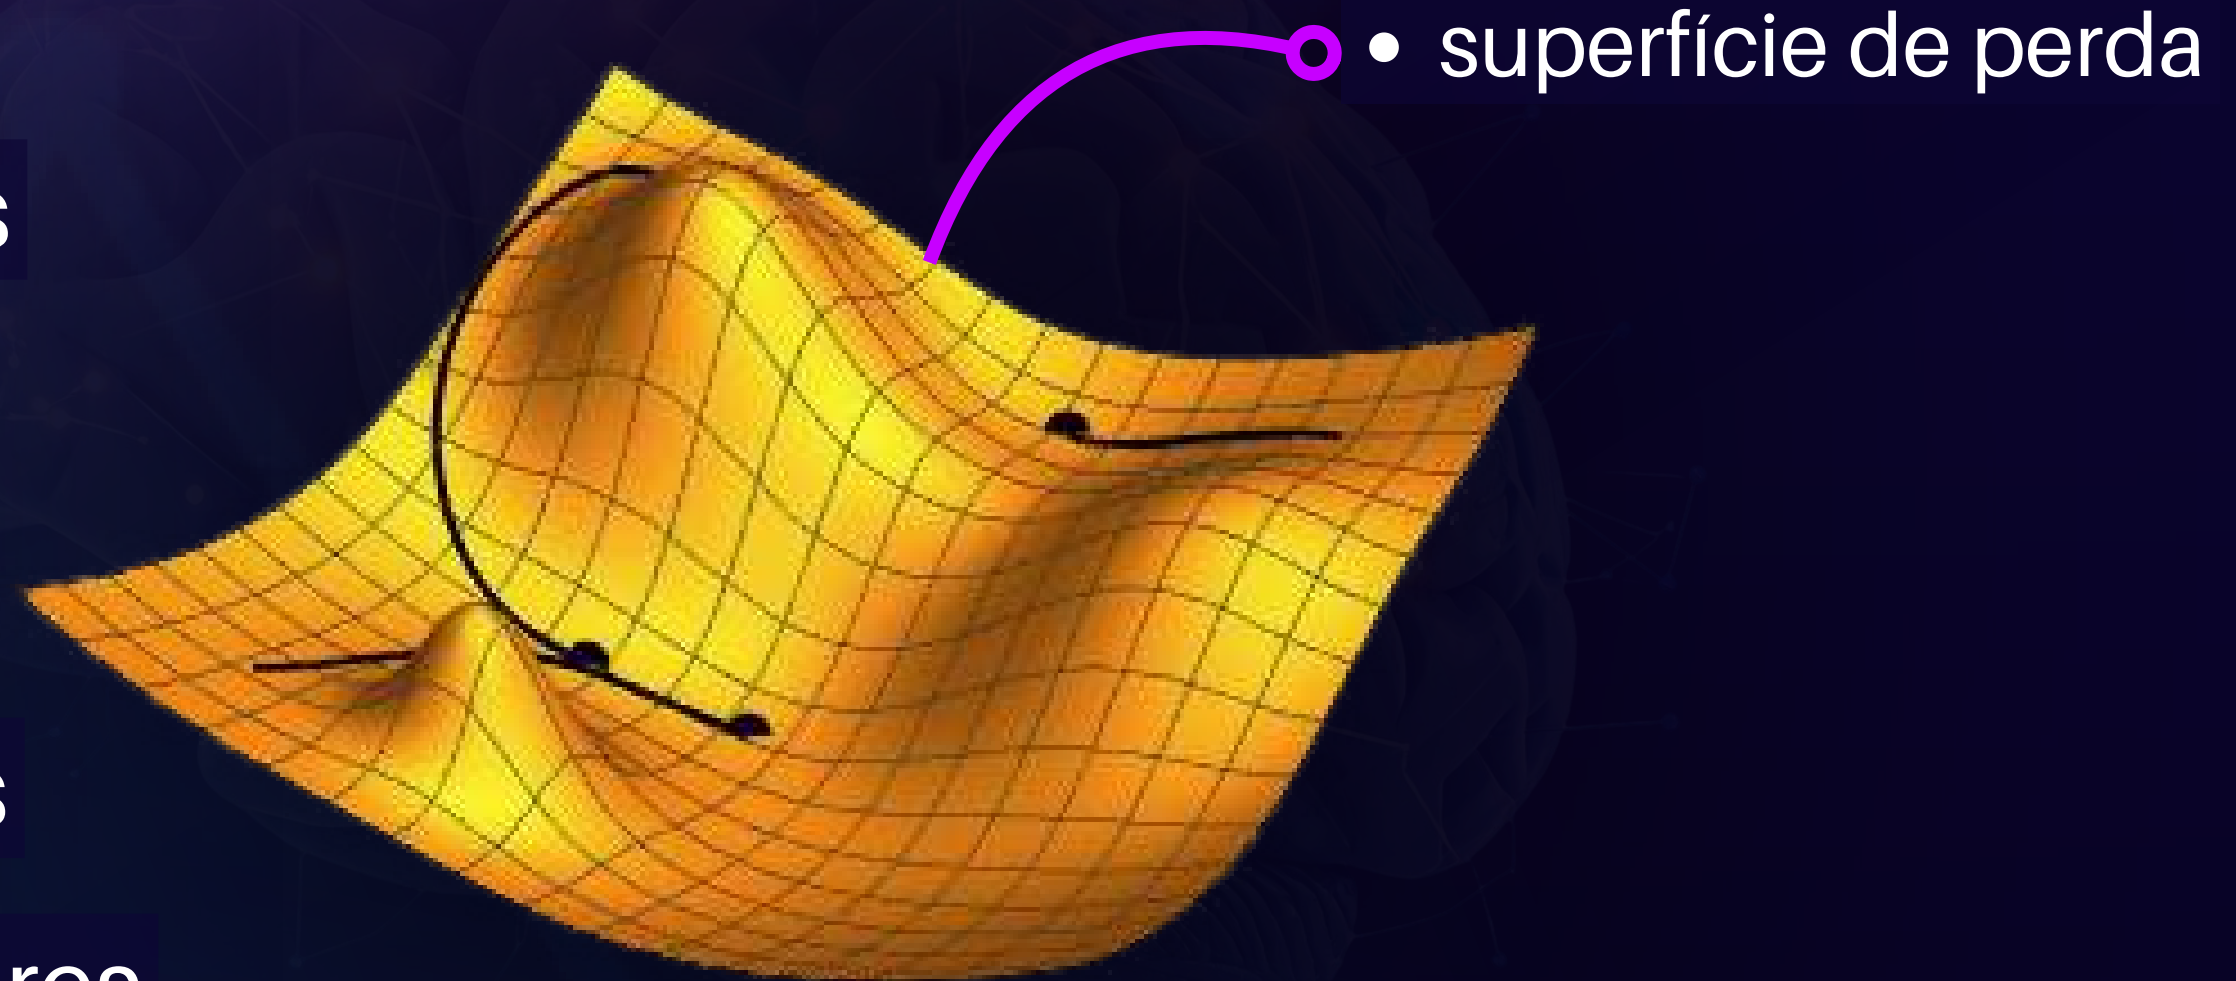


# OTIMIZAÇÃO

## Gradiente Descendente

- padrão para tarefas de Classificação

- A partir de iterativas repetições, reduz o erro e ajusta os valores de  $w$  e  $b$ .



LOSS FUNCTIONS

# OTIMIZAÇÃO

## Gradiente Descendente

- padrão para tarefas de Classificação

$$\hat{b} := \hat{b} - \alpha \frac{\partial}{\partial \hat{b}} L(\hat{b}, \hat{w})$$


- A partir de iterativas repetições, reduz o erro e ajusta os valores de  $w$  e  $b$ .

$$\hat{w} := \hat{w} - \alpha \frac{\partial}{\partial \hat{w}} L(\hat{b}, \hat{w})$$

# backpropagation



- ajusta os pesos das conexões para minimizar o erro entre a saída prevista e a saída desejada
- usando o gradiente descendente para atualizar os pesos em direção ao mínimo de erro



BACKPROPAGATION



## Por que classificar Imagens?

- **Sistemas modernos classificam imagens com base na sua aparência (cor e textura)**
- Então, o que fazer com variações de iluminação, escorço, oclusão, deformação, etc?



Encurtamento



Aspecto



Oclusão



Deformação

# IMPLEMENTAÇÃO



REDES DE CAMADAS  
TOTALMENTE CONECTADAS