






TURMA DO CLASSROOM




CONCETOS

REDES DE CAMADAS
TOTALMENTE CONECTADAS




NEURÔNIO HUMANO

Perceptron



PERCEPTRON


- Input: dado de entrada
- Peso: significância do sinal
- Bias: constante de aumento ou diminuição do valor líquido obtido por xw
- Output: sinal de saída



$$y = xw + b$$

equação de reta



$$y = xw + b$$





LINEARIDADE

- Essas operações são lineares, de forma que, por mais complexa que seja a rede neural, ela só pode captar relações lineares entre as variáveis de entrada e a variável de saída.
- Para torná-las capazes de modelar também relações não-lineares, os resultados de saída de cada camada passaram a ser processados pelas chamadas funções de ativação

sigmoid





reLU



FUNÇÃO DE ATIVAÇÃO

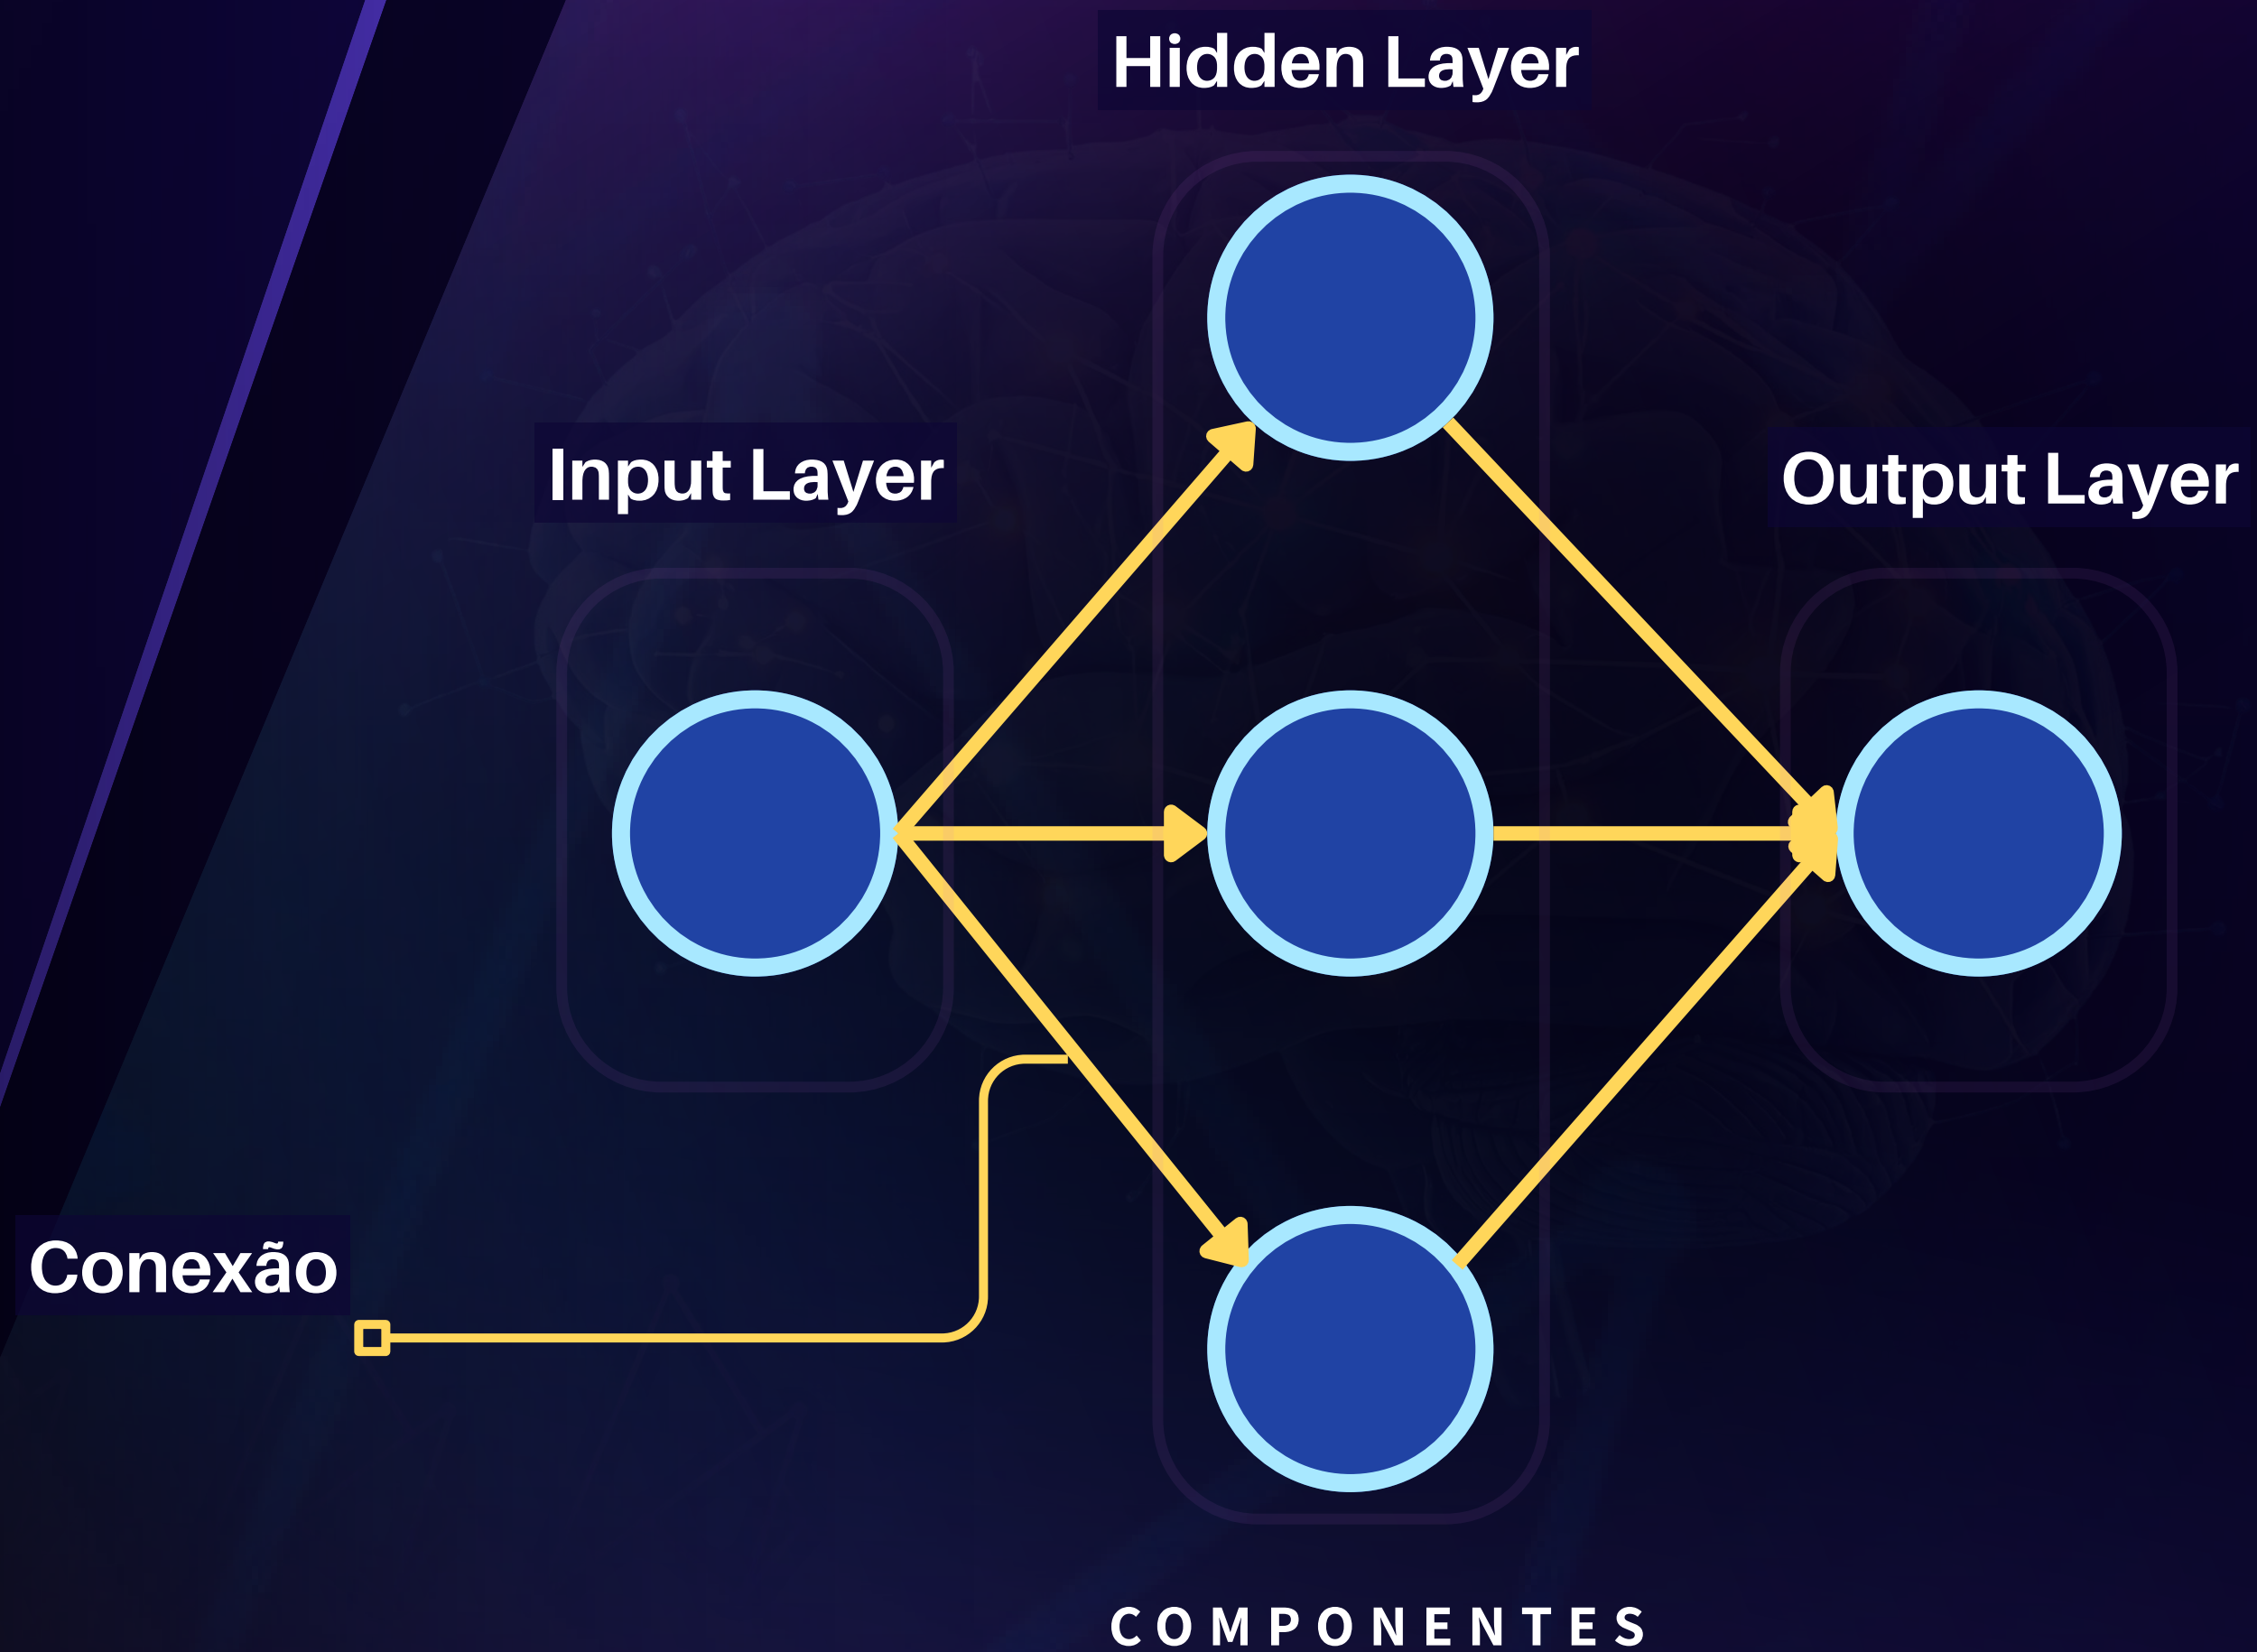
Como o peso e o bias altera a saída

$$w_1 = 3.4, b_1 = 0$$



créditos: Machine
Learning para humanos


P E S O E B I A S



feedforward



- Em uma rede feedforward, cada camada se conecta à próxima camada, porém não há caminho de volta.
- Todas as conexões portanto, têm a mesma direção, partindo da camada de entrada rumo a camada de saída.



FEEDFORWARD

Medidas de desempenho

- **classe positiva**

Representa o resultado de interesse, e responde a pergunta: Esse é o resultado que eu procurava?

- **classe negativa**

É a ausência da classe negativa (ex: o paciente não está doente)

- **legenda**

- VP (Verdadeiro Positivo): Acertos corretos da classe positiva.
- VN (Verdadeiro Negativo): Acertos corretos da classe negativa.
- FP (Falso Positivo): Erros onde o modelo previu positivo, mas era negativo.
- FN (Falso Negativo): Erros onde o modelo previu negativo, mas era positivo.

Medidas de desempenho

- **acurácia**

proporção total de predições corretas (acertos gerais) sobre o número total de observações.

$$Acurácia = \frac{VP + VN}{VP + VN + FP + FN}$$

- **precisão**

Responde à pergunta: "Das vezes que o modelo previu positivo, quantas vezes ele acertou?"

$$Precisão = \frac{VP}{VP + FP}$$

- **recall**

Responde à pergunta: "De todos os casos positivos reais, quantos o modelo conseguiu encontrar?"

$$Recall = \frac{VP}{VP + FN}$$

- **f1 score**

É a média harmônica da Precisão e do Recall. Oferece um equilíbrio entre essas duas métricas em um único valor.

$$F1-Score = 2 \cdot \frac{Precisão \cdot Recall}{Precisão + Recall}$$



DA ARQUITETURA

REDES DE CAMADAS
TOTALMENTE CONECTADAS



Por que classificar Imagens?

Diagnóstico Médico

Controle de qualidade Industrial


Reconhecimento de objetos

Sistemas de Segurança

Mídia Social e Marketing

REDES DE CAMADAS
TOTALMENTE CONECTADAS

Representação de imagens no computador



IMAGENS

Definição

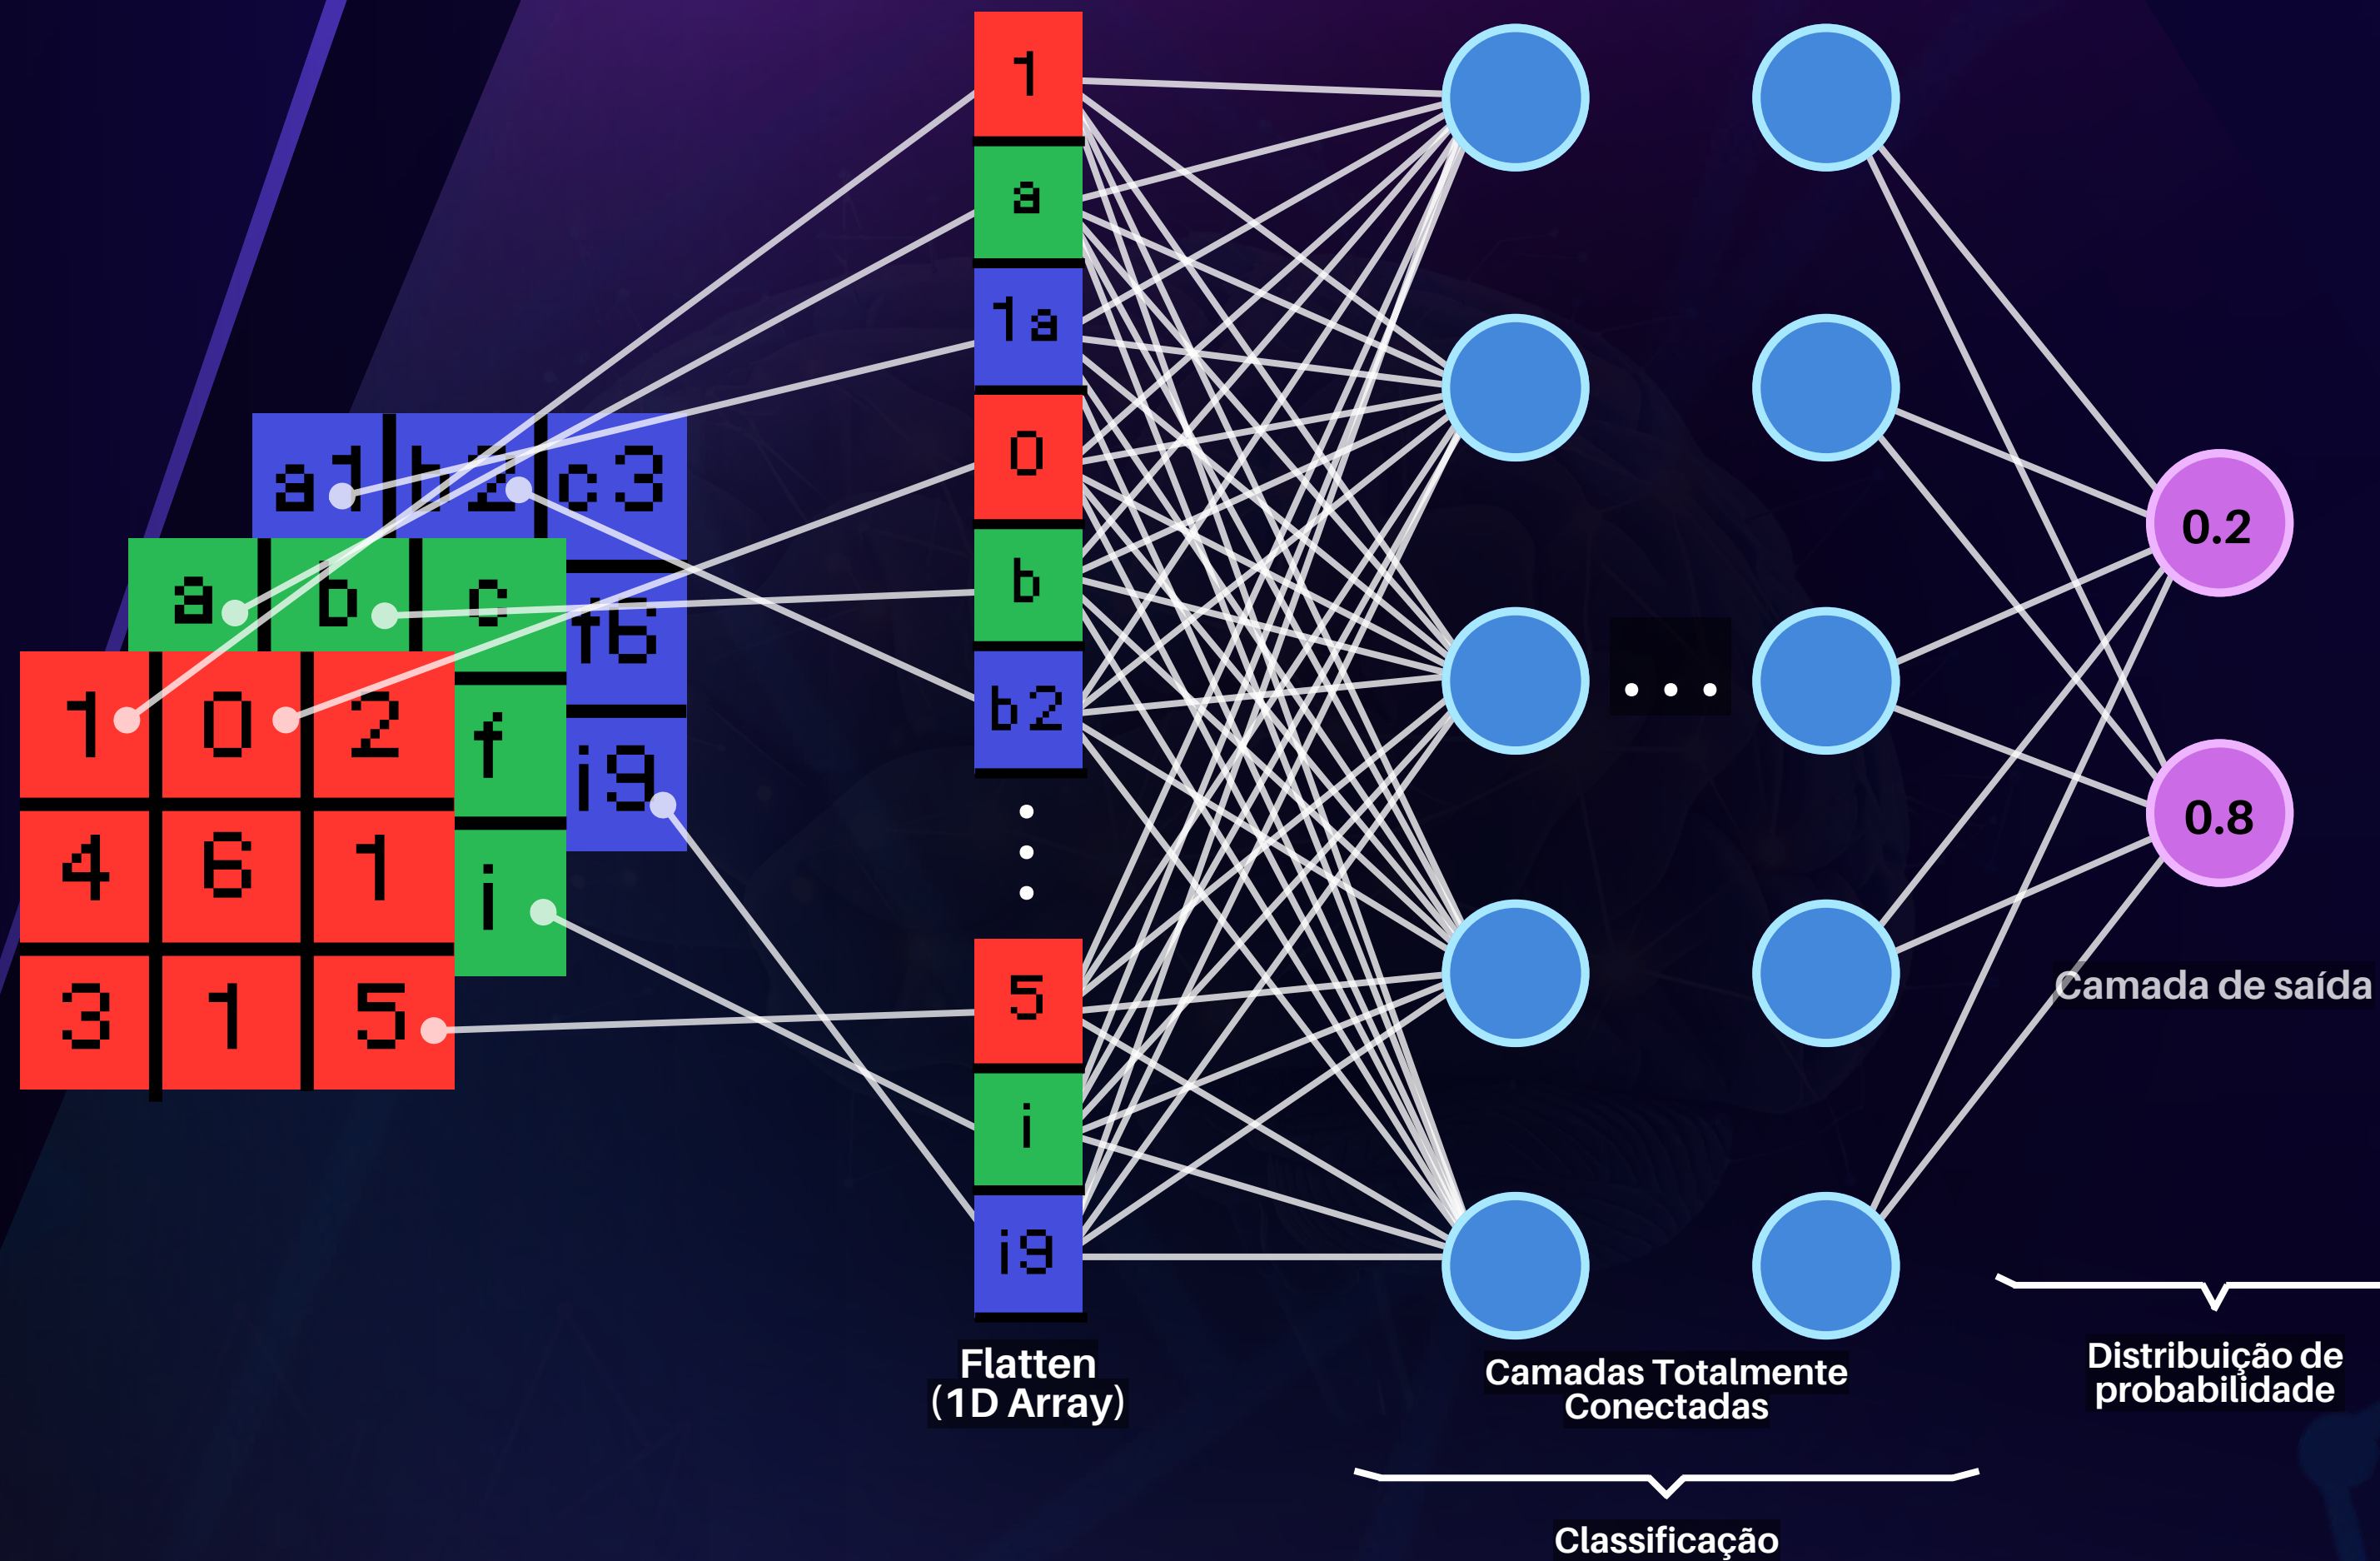
		224	222	226	234	221
	341	321	317	345	367	
154	156	158	160	163	317	224
156	158	163	216	224		234
154	156	158	160	163		226
158	168	116	224	234		234
160	163	173	186	221		

$(5 \times 5) \times 3$

IMAGENS

Também chamada de Rede Neural Densa, As redes neurais de camadas totalmente conectadas são Redes de Perceptrons multicamadas.

Ou seja, cada neurônio de uma camada conecta-se a todos os outros neurônios da camada seguinte.



TOTALMENTE CONECTADA

Classes dizem respeito aos rótulos usados para classificar algo

Em modelos multi-classes, o número de neurônios da camada de saída é igual ao número de classes que o modelo pode prever. Saídas com 1 único neurônio são chamadas geralmente de classificação binária.

Modelos multirrótulo possuem múltiplas saídas independentes, onde cada saída indica a presença ou ausência de um rótulo específico, permitindo que uma mesma imagem pertença a várias classes.

dataset original

**seleção aleatória
de dados**


normalização
(Scaling)

teste

validação

treino

**DIVISÃO TREINO-TESTE-
VALIDAÇÃO**





UNDERFIT E OVERFIT

Underfitting é um problema que ocorre quando o modelo não consegue aprender padrões suficientes dos dados de treino, apresentando métricas ruins já no treinamento e, consequentemente, também baixo desempenho em validação e teste.

Overfitting é um problema que aparece quando o modelo aprende tão bem com os dados de treino, incluindo ruídos e detalhes irrelevantes, que perde sua capacidade de generalização.



MATEMÁTICA

REDES DE CAMADAS
TOTALMENTE CONECTADAS

ERRO

muito errado

ótimo



ERRO

funções de erro

mede o quão ruim está a parada

- previsão de valores contínuos

função de erro

Regressão

Erro Médio Absoluto

Raiz do Erro Médio Absoluto

Raiz do Erro Médio Absoluto

Log cosh loss

Poisson

Classificação

Entropia Cruzada

Hinge Loss

Entropia Categórica Cruzada

- previsão de classes discretas

LOSS FUNCTIONS

funções de erro

Entropia Cruzada

- padrão para tarefas de Classificação

$$\mathcal{H}(x, y) = -\sum_i p(x) \log_q(x)$$

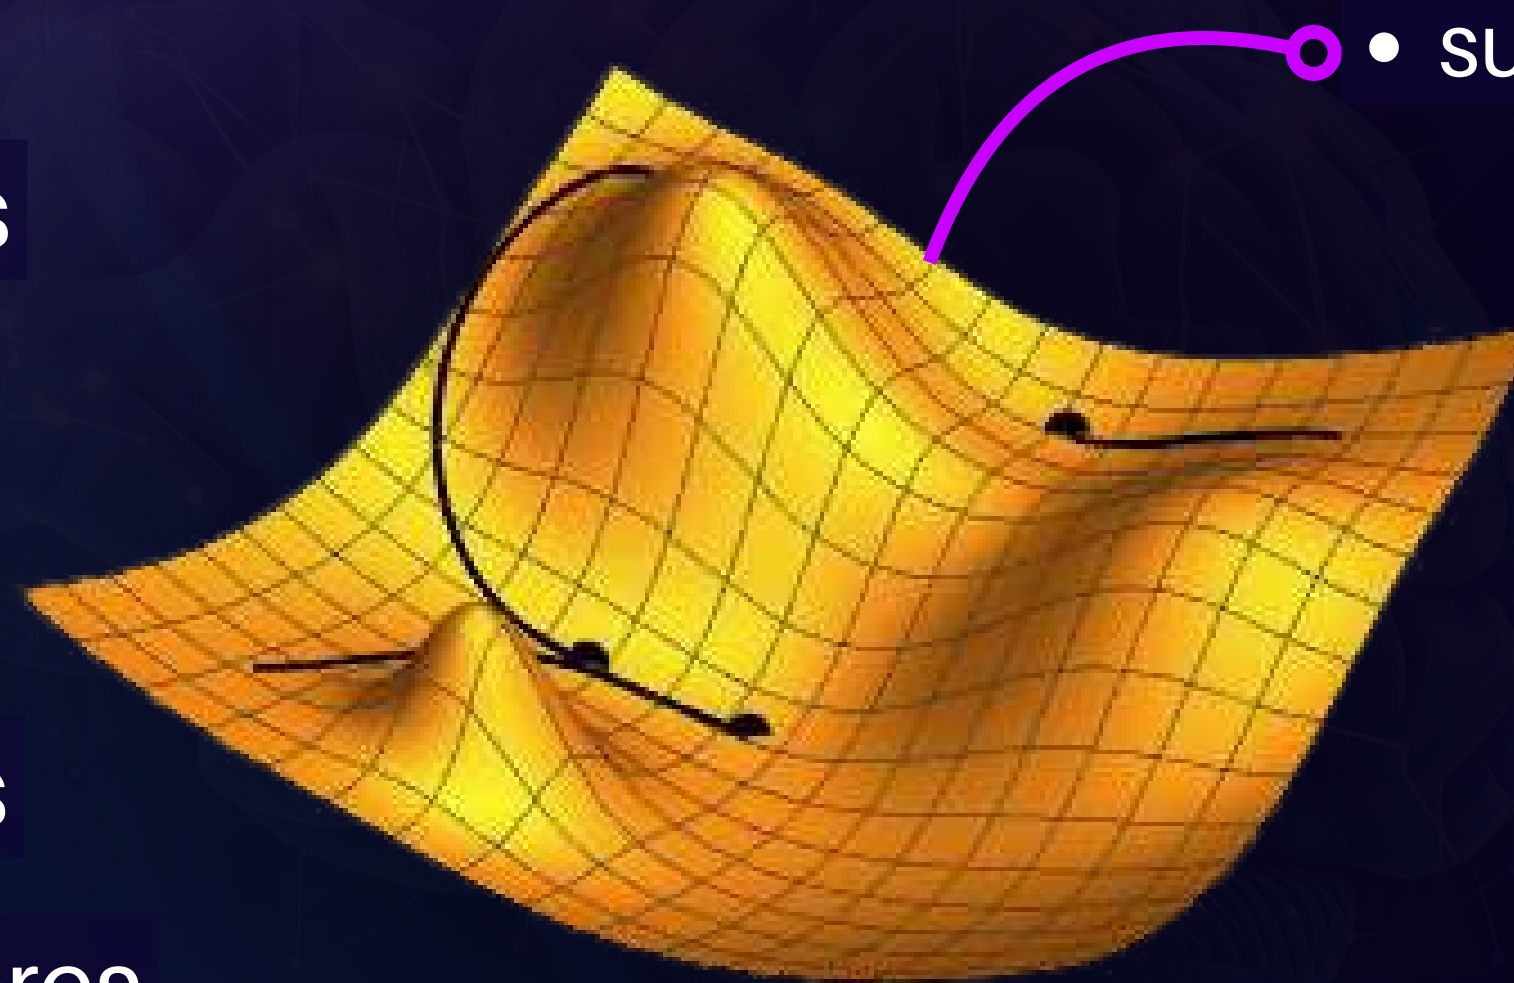
- A superfície de perda possui o formato de uma curva de decaimento logarítmico

OTIMIZAÇÃO

Gradiente Descendente

- padrão para tarefas de Classificação

- A partir de iterativas repetições, reduz o erro e ajusta os valores de w e b .



• superfície de perda

LOSS FUNCTIONS

OTIMIZAÇÃO

Gradiente Descendente

- padrão para tarefas de Classificação

- A partir de iterativas repetições, reduz o erro e ajusta os valores de w e b .


$$\hat{b} := \hat{b} - \alpha \frac{\partial}{\partial \hat{b}} L(\hat{b}, \hat{w})$$

$$\hat{w} := \hat{w} - \alpha \frac{\partial}{\partial \hat{w}} L(\hat{b}, \hat{w})$$

backpropagation



- ajusta os pesos das conexões para minimizar o erro entre a saída prevista e a saída desejada
- usando o gradiente descendente para atualizar os pesos em direção ao mínimo de erro



BACKPROPAGATION

Por que classificar Imagens?

- **Sistemas modernos classificam imagens com base na sua aparência (cor e textura)**
- Então, o que fazer com variações de iluminação, escorço, oclusão, deformação, etc?



Encurtamento



Aspecto



Oclusão



Deformação

IMPLEMENTAÇÃO



REDES DE CAMADAS
TOTALMENTE CONECTADAS